

UVOD U PODATKOVNU ZNANOST

Predikcija sreće pojedinih zemalja

Projektna dokumentacija

Kolegij: Uvod u podatkovnu znanost

Tema: Predikcija indeksa sreće (happiness score)

Skup podataka: World Happiness Report (2015. -- 2019.)

Autori: Marko Samardžić, Jurica Stjepanović, Ivan Nikić

FSRE

Akadska godina 2025./2026.

Sadržaj

1. Uvod	3
2. Opis i analiza skupa podataka	3
2.1 Izvor i kontekst skupa podataka	3
2.2 Struktura podataka	4
2.3 Ciljna varijabla	4
2.4 Pretprocesiranje i priprema podataka	5
3. Modeliranje problema	7
Osnovna ideja algoritma	7
Pretpostavke	7
Prednosti i nedostatci	7
Ponašanje u slučaju neuravnoteženih razreda	7
3.1 Postavljanje problema i treniranje modela	8
4. Evaluacija i testiranje	9
4.1 Metodologija evaluacije	9
4.2 Evaluacija regresijskog modela	9
4.3 Evaluacija klasifikacijskog modela	11
5. Rasprava i kritički osvrt	13
Ograničenja rješenja	13
Kvaliteta modela	13
Moguća poboljšanja	13
6. Zaključak	13
7. Prilog	14
Korišteni alati i tehnologije	14
Ponovljivost	14
Izvor podataka	14
Sažetak ključnih brojki	14

1. Uvod

Sreća stanovništva sve se češće promatra kao mjerilo razvijenosti društva koje nadopunjuje klasične ekonomske pokazatelje poput bruto domaćeg proizvoda. Dok BDP mjeri ekonomsku aktivnost, on ne govori izravno o tome koliko su ljudi zadovoljni svojim životom. Upravo iz te potrebe nastao je **World Happiness Report** — godišnji izvještaj koji na temelju ankete Gallup World Poll rangira zemlje prema subjektivnoj procjeni životnog zadovoljstva njihovih građana.

Problem koji se u ovom projektu rješava jest **predikcija indeksa sreće (happiness score) pojedine zemlje** na temelju skupa društveno-ekonomskih čimbenika kao što su bruto domaći proizvod po stanovniku, socijalna podrška, očekivani zdravi životni vijek, sloboda životnog izbora, velikodušnost i percepcija korupcije. Budući da je ciljna varijabla kontinuirana numerička vrijednost, riječ je o **regresijskom problemu** nadziranog strojnog učenja.

Problem je relevantan iz više razloga. Indeks sreće danas koriste vlade, međunarodne organizacije i civilno društvo kako bi usmjerili javne politike i procijenili napredak društva izvan čisto ekonomskih okvira. Razumijevanje **kojih čimbenika i u kojoj mjeri** doprinose sreći omogućuje donositeljima odluka da prioritiziraju ulaganja (primjerice u zdravstvo ili institucije povjerenja). S podatkovno-znanstvenog gledišta skup je zanimljiv jer kombinira realne, šumovite i nesavršene podatke prikupljene anketom, s jasnom i interpretabilnom ciljnom varijablom, što ga čini pogodnim za primjenu i usporedbu regresijskih modela.

Cilj projekta:

- izgraditi i usporediti regresijske modele koji predviđaju indeks sreće zemlje iz njezinih društveno-ekonomskih čimbenika;
- provesti čišćenje i pripremu podataka (obrada nedostajućih i ekstremnih vrijednosti) te eksploratornu analizu kako bi se razumjeli odnosi među varijablama;
- identificirati čimbenike koji najviše utječu na sreću pomoću važnosti značajki i koeficijenata modela;
- kvantitativno evaluirati kvalitetu modela odgovarajućim metrikama te kritički prokomentirati rezultate, ograničenja i moguća poboljšanja.

U sklopu projekta korišten je objedinjeni skup podataka za razdoblje od **2015. do 2019. godine**, čime je dobiven dovoljno velik uzorak za pouzdanu podjelu na skup za učenje i skup za testiranje te za stabilnu procjenu performansi modela.

2. Opis i analiza skupa podataka

2.1 Izvor i kontekst skupa podataka

Skup podataka preuzet je s platforme Kaggle pod nazivom **World Happiness Report** (izvor: kaggle.com/datasets/unsdsn/world-happiness). Podatke objavljuje **Sustainable Development Solutions Network (SDSN)** pri Ujedinjenim narodima, a temelje se na anketi **Gallup World Poll**.

Indeks sreće dobiven je tzv. Cantrilovom ljestvicom: ispitanike se traži da zamisle ljestve s deset stuba, gdje stuba 0 predstavlja najgori, a stuba 10 najbolji mogući život, te da na njoj odrede gdje trenutačno stoje. Nacionalni prosjek tih odgovora čini indeks sreće. Uz indeks, skup sadrži procjene

doprinosu šest čimbenika koji objašnjavaju zašto je životna procjena u nekoj zemlji viša nego u hipotetskoj zemlji „Dystopia“ s najnižim svjetskim vrijednostima.

Područje primjene je interdisciplinarno — obuhvaća ekonomiju, sociologiju, javno zdravstvo i javne politike. **Svrha skupa podataka** jest mjerenje i međunarodna usporedba subjektivne dobrobiti te povezivanje razine sreće s društveno-ekonomskim uvjetima u pojedinim zemljama.

2.2 Struktura podataka

Izvorni skup sastoji se od pet zasebnih datoteka (po jedna za svaku godinu od 2015. do 2019.). Nazivi stupaca razlikuju se kroz godine, no oni opisuju iste pojmove, pa su stupci najprije **ujednačeni u jedinstvenu shemu** i objedinjeni u jednu tablicu uz dodatak stupca **godina**. Objedinjeni skup sadrži **782 uzoraka** (parova zemlja–godina). Broj zapisa po godinama prikazan je u nastavku.

Godina	2015.	2016.	2017.	2018.	2019.	Ukupno
Broj zemalja	158	157	155	156	156	782

Tablica 1. Broj zapisa (zemalja) po godini u objedinjenom skupu.

Nakon ujednačavanja skup ima **devet stupaca**: jednu kategorijsku varijablu (naziv zemlje), jednu cjelobrojnu (godina), ciljnu numeričku varijablu (indeks sreće) te šest numeričkih značajki. Značenje varijabli prikazano je u Tablici 2.


Varijabla	Tip	Opis
country	kategorijska	Naziv zemlje (identifikator, ne ulazi u model)
year	cjelobrojna	Godina izvještaja (2015.–2019.)
happiness_score	numerička (cilj)	Indeks sreće na Cantrillovoj ljestvici (0–10)
gdp_per_capita	numerička	Doprinos BDP-a po stanovniku
social_support	numerička	Doprinos socijalne podrške (obitelj, zajednica)
healthy_life_expectancy	numerička	Doprinos očekivanog zdravog životnog vijeka
freedom	numerička	Doprinos slobode životnog izbora
generosity	numerička	Doprinos velikodušnosti (donacije)
corruption	numerička	Doprinos (niske) percepcije korupcije

Tablica 2. Varijable u objedinjenom skupu podataka i njihovi tipovi.

Nedostajuće vrijednosti: u cijelom objedinjenom skupu pronađena je samo jedna nedostajuća vrijednost — vrijednost percepcije korupcije za Ujedinjene Arapske Emirate u 2018. godini. Sve ostale značajke potpuno su popunjene, pa je skup vrlo čist po pitanju nedostajućih podataka.

2.3 Ciljna varijabla

Ciljna varijabla je **happiness_score** (indeks sreće) — nacionalni prosjek odgovora na Cantrillovoj ljestvici od 0 do 10. Viša vrijednost znači veću prosječnu subjektivnu dobrobit stanovništva. U objedinjenom skupu vrijednosti se kreću od **2,693** do **7,769**, uz prosjek od 5,379 i standardnu devijaciju 1,127. Medijan (5,322) vrlo je blizu prosjeku, što upućuje na približno simetričnu raspodjelu bez izraženih ekstrema. Za ilustraciju, u 2019. godini najviše rangirana zemlja bila je Finska (7,769), a najniže Južni Sudan (2,853).



Slika 1. Distribucija indeksa sreće u objedinjenom skupu (2015.–2019.).

Kako je ciljna varijabla **kontinuirana**, problem se prirodno modelira kao **regresija**. (U poglavlju 4.3 dodatno je provedena i klasifikacijska varijanta, gdje je indeks sreće diskretiziran u razrede, kako bi se ilustrirale i klasifikacijske metrike.)

2.4 Pretprocesiranje i priprema podataka

Provedeni su sljedeći koraci pripreme podataka:

1. **Ujednačavanje sheme i objedinjavanje.** Stupci kroz godine preimenovani su u jedinstvene nazive (npr. „Economy (GDP per Capita)“ i „GDP per capita“ → `gdp_per_capita`; „Family“ i „Social support“ → `social_support`) te su sve godine spojene u jednu tablicu uz dodatak stupca godine.
2. **Uklanjanje duplikata.** Provjereni su potpuni duplikati redaka kao i logički ključ (zemlja, godina); pronađeno je 0 duplikata, pa nijedan redak nije uklonjen.
3. **Obrada nedostajućih vrijednosti.** Jedina nedostajuća vrijednost (percepcija korupcije, UAE 2018.) popunjena je medijanom te značajke. Medijan je odabran umjesto aritmetičke sredine jer je otporniji na utjecaj ekstremnih vrijednosti.
4. **Detekcija i obrada ekstremnih vrijednosti.** Ekstremne vrijednosti otkrivene su metodom interkvartilnog raspona (IQR): vrijednost se smatra ekstremnom ako je izvan intervala $[Q1 - 1,5 \cdot IQR, Q3 + 1,5 \cdot IQR]$. Ukupno je detektirano 95 ekstremnih vrijednosti, najviše kod percepcije korupcije (68) i velikodušnosti (17). Budući da te vrijednosti predstavljaju stvarne (rijetke, ali legitimne) zemlje, nisu uklonjene, već su blago „podrezane“ (winsorizacija) na granice IQR-a kako bi se smanjio njihov nesrazmjerni utjecaj na model, dok je ciljna varijabla ostavljena nepromijenjenom.
5. **Standardizacija.** Za linearni model značajke su standardizirane (oduzimanje prosjeka i dijeljenje standardnom devijacijom) kako bi koeficijenti bili međusobno usporedivi i kako razlike u mjernim ljestvicama ne bi dominirale. Modeli temeljeni na stablima (Random Forest, Gradient Boosting) ne zahtijevaju standardizaciju jer su neosjetljivi na monotone transformacije pojedinih značajki.

6. **Kodiranje kategorijskih varijabli.** Jedina kategorijska varijabla (naziv zemlje) je identifikator i ne ulazi u model, pa kodiranje (one-hot) nije bilo potrebno. Time se izbjegava i preprilagodba modela na pojedinačne zemlje.

3. Modeliranje problema

Za rješavanje regresijskog problema korištena su tri modela: **linearna regresija** kao jednostavna i interpretabilna polazna osnova te dva ansambl modela temeljena na stablima odluke — **Random Forest** i **Gradient Boosting** — koji mogu uhvatiti nelinearne odnose i interakcije među značajkama. U nastavku je formalno opisan glavni odabrani algoritam (Random Forest), uz osvrt na linearnu regresiju.

Osnovna ideja algoritma

Linearna regresija pretpostavlja da se ciljna varijabla može izraziti kao težinska linearna kombinacija ulaznih značajki uvećana za konstantu (odsječak). Model uči težine minimizirajući zbroj kvadrata pogrešaka (metoda najmanjih kvadrata). Predikcija je izravna: svaka značajka doprinosi izlazu razmjerno svojoj težini.

Random Forest je ansambl velikog broja stabala odluke. Svako se stablo uči na slučajnom uzorku podataka (bootstrap) i u svakom čvoru razmatra slučajan podskup značajki. Pojedinačno stablo donosi odluku nizom pravila oblika „ako je značajka manja/veća od praga“, dijeleći prostor podataka na sve homogenije dijelove. Konačna predikcija u regresiji je **prosjeak predikcija svih stabala**. Usrednjavanjem mnogo raznovolikih stabala smanjuje se varijanca i sklonost preprilagodbi pojedinog stabla.

Pretpostavke

- **Linearna regresija:** linearan odnos značajki i cilja, neovisnost i približna normalnost reziduala, homoskedastičnost (konstantna varijanca pogreške) te odsutnost jake multikolinearnosti. U ovom skupu BDP po stanovniku i očekivani zdravi život snažno su korelirani ($r \approx 0,78$), što je primjer narušene pretpostavke o multikolinearnosti.
- **Random Forest:** postavlja vrlo malo pretpostavki o obliku odnosa — ne zahtijeva linearnost ni određenu distribuciju značajki te je robustan na multikolinearnost i različite mjerne ljestvice.

Prednosti i nedostatci

- **Linearna regresija — prednosti:** jednostavnost, brzina i visoka interpretabilnost (predznak i veličina koeficijenata izravno govore o utjecaju značajke). **Nedostatci:** ne hvata nelinearne odnose i interakcije te je osjetljiva na ekstremne vrijednosti i multikolinearnost.
- **Random Forest — prednosti:** modelira nelinearnosti i interakcije, robustan je na ekstremne vrijednosti i nepotrebnu standardizaciju te daje procjenu važnosti značajki. **Nedostatci:** slabija interpretabilnost („crna kutija“), veći računalni trošak i sklonost slabijoj ekstrapolaciji izvan raspona viđenih podataka.

Ponašanje u slučaju neuravnoteženih razreda

Budući da je primarni problem **regresijski**, pojam neuravnoteženih razreda izravno se ne primjenjuje; analogni izazov je neravnomjerna pokrivenost raspona ciljne varijable (npr. malo zemalja s vrlo niskim ili vrlo visokim indeksom), zbog čega model može biti precizniji u gušće naseljenom srednjem dijelu raspona. U klasifikacijskoj varijanti (poglavlje 4.3) razredi su namjerno definirani po **tercilima**, čime su po konstrukciji gotovo savršeno uravnoteženi (svaki razred ima približno trećinu uzoraka), pa problem neuravnoteženosti ne utječe na rezultate. Da su razredi bili neuravnoteženi, koristile bi se tehnike poput ponderiranja razreda ili preuzorkovanja, a točnost bi se nadopunila metrikama preciznosti i odziva po razredu.

3.1 Postavljanje problema i treniranje modela

- **Značajke (ulazi):** gdp_per_capita, social_support, healthy_life_expectancy, freedom, generosity, corruption (šest numeričkih značajki).
- **Ciljna varijabla:** happiness_score (kontinuirana).
- **Podjela na skup za učenje i testiranje:** omjer 80:20 uz fiksirano nasumično sjeme (random_state = 42) radi ponovljivosti. To daje 625 uzoraka za učenje i 157 uzoraka za testiranje.
- **Parametri modela:** linearna regresija na standardiziranim značajkama (zadani parametri); Random Forest s 300 stabala; Gradient Boosting sa zadanim parametrima. Za sve je modele korišteno isto nasumično sjeme.
- **Validacija:** uz jednokratnu podjelu provedena je i petostruka unakrsna validacija (5-fold) radi stabilnije procjene generalizacije.

4. Evaluacija i testiranje

4.1 Metodologija evaluacije

Modeli su evaluirani na izdvojenom testnom skupu (20 % podataka koji nisu korišteni pri učenju) te dodatno petostrukom unakrsnom validacijom na cijelom skupu. Time se procjenjuje koliko dobro model generalizira na nove, neviđene podatke, a ne samo koliko je dobro „zapamtio“ podatke za učenje. Za regresiju se izvještavaju metrike MAE, MSE, RMSE i R^2 , a za klasifikacijsku varijantu matrica zabune te točnost, preciznost, odziv i F1-mjera.

4.2 Evaluacija regresijskog modela


Korištene regresijske metrike i njihovo značenje:

- **MAE (srednja apsolutna pogreška):** prosjek apsolutnih razlika između stvarnih i predviđenih vrijednosti; izražena je u jedinicama cilja (bodovi indeksa) i lako je interpretabilna.
- **MSE (srednja kvadratna pogreška):** prosjek kvadrata pogrešaka; jače kažnjava velike pogreške.
- **RMSE (korijen iz MSE):** vraća pogrešku u izvorne jedinice cilja, pa je intuitivnija od MSE.
- **R^2 (koeficijent determinacije):** udio varijance ciljane varijable koji model objašnjava; vrijednost 1 znači savršenu predikciju, a 0 da model nije bolji od predviđanja prosjekom.

Rezultati triju modela na testnom skupu te prosjek R^2 iz unakrsne validacije prikazani su u Tablici 3.


Model	MAE	MSE	RMSE	R^2	R^2 (CV, prosjek $\pm$ std)
Linearna regresija	0,442	0,329	0,574	0,729	0,761 $\pm$ 0,029
Random Forest	0,392	0,254	0,504	0,791	0,805 $\pm$ 0,014
Gradient Boosting	0,411	0,271	0,521	0,777	0,790 $\pm$ 0,017

Tablica 3. Usporedba regresijskih modela na testnom skupu i unakrsnom validacijom.




Slika 2. Usporedba modela po R^2 (lijevo) i MAE (desno).

Najbolje rezultate postiže **Random Forest**, s $R^2 = 0,791$ na testnom skupu i srednjom apsolutnom pogreškom od svega 0,392 boda indeksa (na ljestvici od 0 do 10). Unakrsna validacija daje sličan i stabilan R^2 (0,805 uz malu standardnu devijaciju), što potvrđuje da model dobro generalizira i nije pretjerano prilagođen podacima za učenje. Linearna regresija, iako jednostavnija, također daje solidan rezultat ($R^2 = 0,729$), što govori da su odnosi u podacima dobrim dijelom približno linearni.




Slika 3. Stvarne vs. predviđene vrijednosti za najbolji model (Random Forest).

Na Slici 3 točke su grupirane uz dijagonalu idealne predikcije, što vizualno potvrđuje dobru podudarnost predviđenih i stvarnih vrijednosti. Najveća odstupanja javljaju se u krajnjim dijelovima raspona, gdje je manje podataka.




Slika 4. Važnost značajki prema modelu Random Forest.

Analiza važnosti značajki pokazuje da je **BDP po stanovniku** daleko najutjecajniji čimbenik (relativna važnost 0,519), slijede očekivani zdravi život i sloboda izbora, dok velikodušnost i percepcija korupcije imaju najmanji doprinos. To je u skladu s korelacijskom analizom iz Slike 1 (poglavlja 2.3) i Slike 5, gdje BDP po stanovniku ($r = 0,789$) i očekivani zdravi život ($r = 0,742$) najjače koreliraju s indeksom sreće.



Slika 5. Korelacijska matrica značajki i ciljne varijable.



Slika 6. Odnos četiriju najjače koreliranih značajki i indeksa sreće (s linijom trenda).

4.3 Evaluacija klasifikacijskog modela


Iako je primarni zadatak regresijski, radi cjelovitosti je provedena i klasifikacijska varijanta. Indeks sreće diskretiziran je u **tri razreda** prema tercilima: **niska** ($\leq 4,787$), **srednja** ($4,787-5,918$) i **visoka** ($> 5,918$). Time su dobivena tri gotovo jednako velika razreda (po ~ 261 uzoraka), pa su razredi uravnoteženi. Za klasifikaciju je korišten Random Forest klasifikator uz stratificiranu podjelu 80:20.

Korištene klasifikacijske metrike:

- **Matrica zabune:** tablica koja uspoređuje stvarne i predviđene razrede; dijagonala sadrži točno klasificirane uzorke.
- **Točnost (accuracy):** udio ispravno klasificiranih uzoraka u ukupnom broju.
- **Preciznost (precision):** udio stvarno pozitivnih među svima koje je model proglasio nekim razredom.
- **Odziv (recall):** udio ispravno prepoznatih uzoraka pojedinog razreda među svim stvarnim uzorcima tog razreda.
- **F1-mjera:** harmonijska sredina preciznosti i odziva.

Metrika	Vrijednost
Točnost (accuracy)	77,1 %
Preciznost (makro prosjek)	77,9 %
Odziv (makro prosjek)	77,0 %
F1-mjera (makro prosjek)	77,2 %

Tablica 4. Rezultati klasifikacijske varijante (tri razreda sreće).



Slika 7. Matrica zabune za klasifikaciju u tri razreda sreće.

Model točno klasificira 77,1 % testnih uzoraka. Iz matrice zabune vidljivo je da su pogreške gotovo isključivo „susjedne“ — model miješa srednji razred s niskim ili visokim, ali praktički nikada ne zamijeni nisku s visokom srećom (samo pokoži takav slučaj). To je očekivano i poželjno, jer su granice između susjednih razreda blizu kontinuiranog praga, pa su uzorci na granici teži za razlikovanje. Srednji razred je najteži za klasifikaciju, što odgovara činjenici da se nalazi između dvaju pragova.

5. Rasprava i kritički osvrt

Ograničenja rješenja

- **Priroda značajki.** Šest čimbenika u skupu nisu sirovi pokazatelji (npr. stvarni BDP u dolarima), nego već izvedeni doprinosi koje su autori izvještaja procijenili u odnosu na referentnu „Dystopiju“. Zbog toga su značajke po konstrukciji povezane s indeksom sreće, pa visok R^2 treba tumačiti s oprezom.
- **Izostavljena komponenta.** Izvorni izvještaj sadrži i „Dystopia residual“ koji obuhvaća neobjašnjeni dio; on namjerno nije korišten kao značajka jer bi umjetno napuhao performanse modela.
- **Objedinjavanje godina.** Spajanjem pet godina u jedan skup zanemarena je vremenska ovisnost (ista zemlja pojavljuje se više puta), što može blago precijeniti generalizaciju jer su uzorci iste zemlje međusobno slični.
- **Subjektivnost i veličina uzorka.** Indeks se temelji na anketnoj samoprocjeni, koja je podložna kulturološkim razlikama, a po godini je obuhvaćeno tek oko 150 zemalja.

Kvaliteta modela

Model Random Forest objašnjava približno 79,1 % varijance indeksa sreće uz prosječnu pogrešku od 0,392 boda, što je vrlo dobar rezultat za podatke ovog tipa. Stabilnost rezultata kroz unakrsnu validaciju (mala standardna devijacija R^2) pokazuje da model pouzdano generalizira. Ipak, RMSE od približno 0,504 boda znači da pojedinačne predikcije mogu odstupati i za pola boda, pa model nije prikladan za vrlo precizna pojedinačna rangiranja.

Moguća poboljšanja

- uključivanje regije/kontinenta kao kategorijske značajke (one-hot kodiranje) radi hvatanja regionalnih obrazaca;
- optimizacija hiperparametara (npr. dubina stabala, broj stabala, stopa učenja) pretragom po rešetki uz unakrsnu validaciju;
- primjena regularizirane regresije (Ridge, Lasso) radi ublažavanja multikolinearnosti i odabira značajki;
- dodavanje vanjskih značajki (npr. nezaposlenost, obrazovanje, klimatski pokazatelji) i novijih godina izvještaja;
- isprobani napredniji ansambli (XGBoost, LightGBM) te modeliranje po godinama radi uvažavanja vremenske dimenzije.

6. Zaključak

U projektu je riješen regresijski problem predikcije indeksa sreće zemalja na temelju šest društveno-ekonomskih čimbenika iz izvještaja World Happiness Report za razdoblje 2015.–2019. Podaci su objedinjeni i pripremljeni (ujednačavanje sheme, obrada jedine nedostajuće vrijednosti, detekcija i winsorizacija ekstremnih vrijednosti te standardizacija), a zatim su uspoređena tri modela.

Najbolje rezultate postigao je model Random Forest s $R^2 = 0,791$ i $MAE = 0,392$ na testnom skupu, uz stabilne rezultate u unakrsnoj validaciji. Analiza važnosti značajki i korelacija jasno je pokazala da na sreću najviše utječu BDP po stanovniku te očekivani zdravi životni vijek, dok su velikodušnost i

percepcija korupcije najmanje utjecajni čimbenici. Dodatna klasifikacijska varijanta s tri razreda postigla je točnost od 77,1 %, pri čemu su pogreške gotovo isključivo između susjednih razreda.

Rezultati potvrđuju da se nacionalna razina sreće može vrlo dobro predvidjeti iz dostupnih društveno-ekonomskih pokazatelja, ali i da rezultate treba tumačiti uz svijest o ograničenjima skupa podataka. Predložena poboljšanja (bogatije značajke, optimizacija hiperparametara i uvažavanje vremenske dimenzije) smjernice su za daljnji rad.

7. Prilog

Korišteni alati i tehnologije

- Programski jezik: Python.
- Biblioteke: pandas i NumPy (obrada podataka), scikit-learn (modeliranje i evaluacija), Matplotlib (vizualizacije).
- Modeli: LinearRegression, RandomForestRegressor, GradientBoostingRegressor, RandomForestClassifier (scikit-learn).

Ponovljivost

- Nasumično sjeme: random_state = 42 (podjela podataka i inicijalizacija modela).
- Podjela podataka: 80 % za učenje, 20 % za testiranje; dodatno 5-struka unakrsna validacija.

Izvor podataka

World Happiness Report Dataset, Kaggle (SDSN / Gallup World Poll): <https://www.kaggle.com/datasets/unsdsn/world-happiness>. Korištene su datoteke za godine 2015.–2019., objedinjene u jedinstvenu shemu sa šest zajedničkih čimbenika i indeksom sreće.

Sažetak ključnih brojki

Stavka	Vrijednost
Broj uzoraka (zemlja–godina)	782
Broj značajki u modelu	6
Nedostajuće vrijednosti (obrađene)	1
Detektirane ekstremne vrijednosti	95
Najbolji regresijski model	Random Forest
R ² (test) najboljeg modela	0,791
MAE (test) najboljeg modela	0,392
Točnost klasifikacijske varijante	77,1 %

Tablica 5. Sažetak ključnih brojki projekta.